

第四轮:认错一处、修完三处、E68/E69 待你放行

致评审人:你的第三轮裁定已全部执行。本函(1) 正式撤回我们那条错误的上下界主张;(2) 报告三条修正案的冻结原文;(3) 报告执行你的 episode 口径时发现的一个设计 漏洞(你的规则原样实现会误判连续分化的变体)以及修补方式;(4) 给出仓位口径下 的新实测数字——它比收益口径的结论更硬;(5) 三个新问题。

你点名"开跑前必须修"的两处(EOS 情景边界、episode 定义)均已完成并提交。

1. 认错:"真值必在其间"是错的,已撤回

你的反驳完全成立,我们接受得不打折扣。

我们写的是"可得样本结果与 EOS 归零结果构成上下界,真值必在其间"。这个单调性只在 纯多头、固定仓位、缺失资产不影响信号与其他权重、且统计量线性时才近似成立。我们的 策略一条都不满足:多空双向、波动目标、横截面构造。EOS 的真实价格路径会改变建仓与 退出时点、波动率估计、其他币的权重、换手成本与协方差矩阵;Sharpe 对该路径不 单调,做空时"跌至零"甚至可能是有利情形。

这不是措辞失误,是一个真实的推理错误——把"长期多头累计收益的极端坏情形"直接 推广成了"所有统计量的边界"。已按你给的文本冻结为四情景敏感性 + INCONCLUSIVE_ DATA_GAP 规则:情景跨越判决门槛时,不得由可得样本单独判通过或失败,须取得独立 历史源后重新裁决。

顺带确认你的升级判断:PIT instrument master / 独立历史源由此从"值得买"变成 "完成严格验证所必需"。是否购买仍是资金所有者的决定,但理由已经不是"更好",而是 "免费路径在结构上做不到"。

2. 三条修正案已冻结(原文在 research/log.md)

E68 缺失资产修正案:四情景(missing-as-cash / terminal-total-loss / monotone-delisting-path / 有独立数据时的 observed-coarse-path + 执行 haircut), 全情景同判决 → ROBUST_TO_MISSING_PATH,跨门槛 → INCONCLUSIVE_DATA_GAP。

E68 双臂优先级修正案:按你的矩阵逐格冻结。最关键那行原样写入——A 失败 B 通过时,历史证据降级,B 不得回头挽救 A;B 作为独立版本的新策略候选,不继承 1.11,须独立 clean-room 与前瞻验证。

Champion-Challenger 暴露修正案:主估计量保留全部日历日(含零差异日,因为 "很少触发"本身是该变体的经济属性),主重采样改为联合循环 block bootstrap; 次估计量按 episode 聚类;暴露三口径(独立 episode 数 + 累计 L1 仓位差 + 触发 频率);三态裁决 NO_EXPOSURE / LOW_PRECISION / DECIDABLE。晋升阈值一字未动。

3. 你的 episode 规则有一个漏洞,我们改了(请复核)

按你给的定义直接实现后,一个测试立刻炸了:两本天天都不同的账本,其差异日全部 连续,合并后只剩 1 个 episode,于是被判成"无暴露"——而事实恰恰相反,它是持续 被施用治疗、暴露最充分的情形。

问题出在 episode 合并规则对"稀有触发"和"连续分化"一视同仁。修补(已冻结):

- 触发频率 ≥ 0.5 (即多数日子都不同)= 连续给药,单独满足暴露要求,不再要求 episode 计数;
- 触发频率低时才启用 episode floor(差异日 ≥ 10 且 独立 episode ≥ 3),这正是 你要防的"十个连续日冒充十次独立剂量";
- 两者都必须先过累计 L1 仓位差 ≥ 0.50 的地板。

这样你的原意(防止聚集夸大证据)保留,同时不会把最充分暴露的情形误判为零暴露。 如果你认为连续分化也该要求 episode 多样性(例如担心"天天差一点点"其实是同一个 制度),请给出你的切法,我们在开跑前改。

4. 改用仓位口径后的实测:比收益口径的结论更硬

你要求暴露按仓位而不是收益衡量,理由是收益差会被对冲性调仓抹平、也会被舍入噪声 伪造。已实现(逐日逐币 target_w 的 L1 距离),并对 07-09~07-27 的实盘纸面记录重算:

口径	结果
收益口径(上一轮)	18 天中 1 天差异 $>1bp$ 、2 天 $>0.1bp$
仓位口径(本轮)	19 天中 17 天两账持仓逐字相同,仅 2 天 L1 $>1\%$

也就是说:v2 至今几乎从未被真正测试过——不是"收益碰巧接近",而是它压根没做过 不同的交易。裁决器对这段记录的输出是 None (共同标记 <30 天,按既有规则拒绝 计算),这一点我们保持不变:样本不足时拒绝出数,而不是给一个假精度。

表述纪律也按你的要求收紧:永不触发的过滤器只能称 "observationally equivalent under realized regimes",不得推出"该过滤器在未来深熊 制度下没有价值"。

5. 90 天功效:接受你的部分裁定

接受"具体数字撤回但功效未获证明"的定性。我们的 0.109 是 18 天极小样本下的 nominal MDE,方差估计极不稳定,且如你所说,该差值过程由罕见制度触发,真实不确定性来自 "制度出现频率 $\times$ 触发后条件效果"的乘积,而非常规 MDE 公式假设的稳定差值过程。 我们不再声称"90 天足以检测 $\Delta Sharpe=0.1$ ",只声称"评审第二轮针对本对账本的 16-78 年估计不适用"。

`n_diff_days < 10` 已按你的要求从"最终统计定义"降格为工程保护条件之一,真正的 判据是 episode + 累计暴露 + 精度三者。

6. 三个新问题

1. 零暴露窗口的时间价值:若 v2 在整个 90 天里持仓与 champion 完全相同,10-07 的正确输出显然是 `INCONCLUSIVE_NO_EXPOSURE`。但接下来呢?继续无限期并行、直到 深熊制度出现为止(可能数年),还是设一个"暴露预算耗尽"的终止规则(例如两年内 未获得最低暴露即退役该 challenger)?**无限期等待本身有隐性成本**:它占用监控 注意力,并让"我们有一个平行 A/B"这句话在证据上名不副实。你会怎么定这个终止规则?
2. 条件效应的外推:假设两年后 v2 终于获得 3 个深熊 episode 并显示条件效果为正。 把"3 次触发下的条件效果"外推为"长期部署价值",需要多少次独立 episode 才算够? 在 episode 稀缺时,是否应该改用回测中的历史触发频率作为先验(但那正是我们要 独立验证的东西——这是个循环),还是干脆承认此类变体在前瞻框架内不可判定?

3. 对你自己框架的攻击:你的三层 null(fixed-graph / adaptive-surrogate / conservative-search) 中,B2 需要冻结一个 research-policy surrogate。但这个 surrogate 是我们在已知历史结果之后写的——我们对"研究者会在什么情况下放弃 一个 family"的建模,本身就被我们记得的历史所塑造。这是否让 B2 系统性低估污染? 若是,B2 是否只能被解读为"下界的一个更紧版本",而非你说的"主结果"?

本轮改动:research/log.md 三条修正案(含认错原文)、qtrade/live/stats.py (exposure_series / episode 聚类 / block bootstrap / 三态)、qtrade/live/report.py、 tests(+2,含"十个连续差异日只算一次暴露"与"对冲性调仓收益无差异但仓位有差异"两个 回归用例),163 passed / 6 skipped,已提交。E68/E69 仍未开跑,等你对第 3 节漏洞修补 与第 6 节问题的意见;若你判定第 3 节修补可接受,我们即刻开跑,不再等下一轮。