

GPT 外部评审分诊报告(2026-07-26)

对《qtrade 严格外部审核与重构建议》(GPT, v1.0)的逐条对照仓库现实分诊。 每条判为四类之一:  **真盲区**(采纳,列入行动)/  **已做**(它没看到细节,给 log/代码证据)/  **部分成立**(重标注或部分采纳)/  **用户决策**(涉及钱或 战略取舍,不由我定)。所有历史判断均引 research/log.md 原文核实,非凭记忆。

一、总评:核心结论接受,不辩护

GPT 的总判断——"工程可靠性 9/10、统计推断 5.5/10、实盘证据 2/10,这是一个很强的 研究平台但还不是被证明的赚钱系统"——**全部接受**。它最重的一拳("最大风险不再是 工程 bug,而是严谨地验证了一个已被研究过程污染的历史样本")打在真穴位上:E1-E67 全部向同一段历史提问,预注册冻结了"答题"、没冻结"出题",这一层我们没有任何制度 防御。下面的分诊不改变这个总接受,只区分哪些子弹命中、哪些打在已有装甲上。

计分:评审共 20 个实质论点 ——  **真盲区** 8 条,  **已做** 6 条,  **部分成立** 4 条,  **用户决策** 2 条。事实性错误 2 处(不影响其主旨,见第二节)。

二、先澄清两处事实错误(然后各自引出的真问题仍成立)

1. "etf_trend 33 年历史必然含代理拼接" —— 指控不成立,但引出的真问题成立() 核实 (data_store/etf//1d.parquet 实测 + log E62 原文):没有任何代理/指数/共同基金 回填。10 只 ETF 各按自己实际上市日自然进入面板(GLD 序列就从 2004-11-18 开始, SLV 2006-04-28, UNG 2007-04-18),对齐用 ffill, log 原文"33年窗口(1993起, ETF随上市 入场fill)"。但它逼出了我们标签的真毛病*: "33 年验证"掩盖了早期宇宙极薄—— 1993-1999 只有 SPY 一只, 1999-2002 只有 SPY/QQQ, 2007 年后才是完整 10 只。 2000 年"危机年为正"实质是两只 ETF 的样本。→ 行动 P0-3:证据重标注,分时代报 宇宙宽度与分段指标, log 追记。

2. "cn_futures 连续合约/roll 真实化仍需复核" —— 已做,且是仓库里做得最重的一块() E50 首跑就发现拼接污染是一阶的(交易所主力连续 Sharpe 0.08), E50b 推倒重来: 逐合约档案 1178 个文件、自建后复权拼接(昨日持仓量定主力、只许向后换月、无前视, 规则冻结在 qtrade/data/cn_futures.py)、换月缺口逐品种审计(I 6.5%/J 4.1%/RU 3.6%)、换月成本估 0.36%/年诚实扣除(Sharpe 0.48→0.41 压线仍过, log E50b 原文)。 GPT 建议的"真实 roll 审计"就是 E50b 本身。未做的半句是"独立复现"——成立,并入 P1-7。

三、被证实的真盲区(,按危险度排序)

3.1 crypto 宇宙选择偏差 —— 评审全篇最有价值的一条,且比它说的还严重

核实结果比 GPT 的怀疑更难看,如实摆出:

- 旗舰数字 Sharpe 1.11 来自 E23 六币七年面板(BTC/ETH/XRP/ADA/LTC/LINK, 2019-07 起, OKX 历史上限); 10 币面板只有 2021 年起(SOL/AVAX/DOT 数据 2021-01 才有)。我们自己的评审简报

把"10 币"和"7 年 1.11"写在同一段——这个 合并陈述本身就夸大了证据,GPT 都没抓到,这里自曝并勘误。

- 六币不是 2019 年时点的前六大:LINK 在 2019-07 市值排名 15 名开外,是事后 赢家;ADA 也在边缘。而 2019 时点真实的头部币 EOS/BCH/BSV/TRX(后来的输家)不在池内。这正是教科书式的幸存者/选择偏差。
- 各币数据起点是**抓取截断日而非上市日**(SOL 实际 2020 年就上市了,我们的数据 从 2021-01 开始)——面板窗口由数据可得性决定,不是研究设计决定。
- 已有的缓解(如实列,但不够):E28 扩池 10→16 被拒(预注册门槛)、universe_score 季度 LOO 边际贡献背书(10/10 正、池外 6/6 负)、换池须过预注册双面板门槛不追 排名。这些防的是"未来乱动",防不了"初始十个怎么来的"。

→ 行动 P0-1(E68 预注册):2019 时点宇宙对照实验。用 2019-07 CMC 市值快照 选时点 top 币(会包含 EOS/BCH/TRX 这类后来的输家),补抓它们 2019 起的 1h 数据 (OKX/kraken 免费可得),冻结的策略原样跑,对照现宇宙的 Sharpe 差 = 选择偏差的 定价。若时点宇宙 Sharpe 掉到 0.5 以下,crypto_core 的证据等级和实盘讨论都要降档。 这是全项目当前性价比最高的一个实验,GPT 的 30 天清单第 2 条与此同构。

3.2 策略层多重检验空白(因子层有,策略层无)

GPT 说"家族性多重检验缺失"——**因子层其实有**:E59 用 Harvey-Liu-Zhu $t \geq 3.5 + 100$ 组随机对照(log 原文:"461 因子若用 95 分位门槛会放进 ~22 个纯噪声因子"),且 E59 的判决就是 HLZ 的现场演示(全部无增量)。但**策略/实验层(E1-E67 这一层)确实什么都没有**,简报里我们自己也披露了。可行性分诊: -

DSR(Deflated Sharpe):可做,单 Mac 免费——需要试验族数估计(见 3.3)+ 收益偏度/峰度,对 crypto_core 1.11 与 cn_futures 0.48 各算一个打折后数字。 - **PBO/CSCV:对历史实验不可复原**(需要每次试验全部候选的收益序列,当年没存),只能作为制度对未来实验生效。 - **White RC/SPA:同上**,需要完整候选池序列。诚实结论:历史部分能补的只有 DSR;PBO/SPA 写进未来实验的判决模板。→ P0-2。

3.3 真实试验数没有台账

"67 个编号实验只是 trial count 下界"——正确。参数敏感性、放弃的图表观察、同一 实验内的参数格点都没计入。→ P0-2:回溯 E1-E67 建 trial-family 清单(family_id/ 经济假设/候选数估计),给出保守的 effective N,喂给 DSR。以后 log 判决模板加 candidate_count 字段。

3.4 Placebo/负对照缺失

系统只证明过"好策略能过门槛",从没证明过"垃圾策略会被杀"。1000 个随机信号/ 打乱收益/随机参数的策略过同一回测器+同一成本模型,画出噪声 Sharpe 分布 = 假阳性底噪。单 Mac 一夜能跑完。→ P0-4(E69 预注册)。

3.5 研究过程污染无台账 + "Nuclear Holdout"的诚实回应

Data Exposure Registry 采纳(轻量版:一个 registry 文件,记每段数据被哪些实验 看过)。但 **Nuclear Holdout 对已有数据在物理上不可能**——2019 起的 crypto、2018 起的商品、全部 A 股历史都被 E1-E67 暴露,封存无意义。唯一未暴露的数据 是**未来**——这正是九本前瞻纸面账的设计逻辑,GPT 自己的评分表也把 forward/live 放在证据顶层。所以:registry 建(P1-6),vault 只对未来新数据源生效(如将来买的 分钟线),而"前瞻账本=事实上的 holdout"这个定位写进方法论文档。

3.6 判决无数据快照哈希

属实。判决锚在"冻结代码+预注册日期+存档 CSV",免费数据源事后改历史(复权、补数据)会让"commit 不变"≠"可复现"。→ P1-6:snapshot manifest(判决时对所用 parquet 记 content hash + 成本模型版本 + 日历版本),未来判决强制,历史判决补 "当前状态哈希"并标注为事后。

3.7 独立复现缺失 + 一个 GPT 没点破的加重因素

clean-room replication 采纳(P1-7:crypto_core 用第二数据源 kraken/binance bars、不 import 现有回测器、独立实现信号→仓位→成本→P&L,逐日 diff)。自曝一个 GPT 没写的加重因素:本项目策略、回测器、审计脚本出自同一个 AI 助手之手,共因 错误的相关性比人类单作者更高,不是更低——同一套先验、同一类盲点、同一天的 习惯写法。独立复现对本项目比对普通单人项目更必要。

3.8 llm prompt 无哈希

模型已钉死(claude-sonnet-5 / claude-haiku-4-5,E60 预注册原文),全文决策存档,但 system prompt 本身没有哈希,静默漂移无法证伪。→ P0-5:每日决策 JSON 加 prompt_sha256,变更即触发预注册修正。

四、部分成立(🟡)

4.1 "1.5x maxDD 无概率意义" —— 统计定性完全正确(极值统计量,样本越长 maxDD 越大)。但实际体系不是裸 1.5x,而是已有三层:decay 状态机 1.0x 警告 / 1.25x 衰减(连续 2 周警告触发人工复审,qtrade/live/decay.py)→ 1.5x 断路。GPT 的三分法映射:survival stop=用户资本决策(实盘开关本来就在用户,金额由 用户定);exposure stop=RiskGate 的 gross/单票钳制已有;degradation detector=decay.py 已有雏形,缺的是正式变点检验 → P2-9:decay.py 加 CUSUM。

4.2 A 股执行真实化清单(队列/部分成交/集合竞价/板块规则/废单)—— 方向全对,分诊按纸面阶段的边际价值:partial fill 一等状态采纳(target→filled→remaining→ next-session retry,QMT 激活日前做进 qmt_exec,P1-8);board rules PIT 数据库、集合竞价细分推迟到有真实拒单/成交数据再建——在纸面阶段建这些是在没有测量 手段的情况下堆假设。GPT 说"日线只能作保守模型,不能当 fill simulator"——同意,这正是 E67 判决把复活钥匙设成"QMT 实测 TCA <5bp"而非再加模拟的原因(log 原文)。月频 top-50 沪深300 大盘股的队列风险数量级本来也远小于小票高频。

4.3 llm_agents A/B 不纯 —— 约束确实不同(单币 0.10 vs 0.25、gross 1.0 vs 2.0、熔断 0.15 vs 0.23、1d vs 1h),这是预注册时明知并写明的选择("无回测可定标,故 更紧",E60 原文)。但 GPT 的归因批评成立:直接比 Sharpe 混淆了"LLM 判断力"与 "风险预算差异"。→ 2027-01 评估日前提提交预注册修正:判决维持原门槛不动,加一个 vol-matched 分析层(同波动预算下比 alpha/换手/暴露),归因和判决分开。

4.4 组合层建议(evidence-weighted risk budgeting)—— 方向同意。现状核实:组合层 E51b 只对验证账本生效且只是 inverse-vol,从未上 Markowitz(GPT 警告的 "复杂优化器成为新的过拟合机器"我们本来就没犯)。验证账本目前只有 2 本 (crypto_core/cn_futures),协方差感知的风险预算在 N=2 时无意义;等第 3 本账 过验证时采纳该设计,写入组合层文档作为预注册的升级路径。

五、已做——GPT 未见细节(●,只列结论与出处)

评审建议	仓库现实
funding rate 需真实历史	未入回测但两次实测定偏:E17 叠加真实 funding -0.07%/年;E56 对齐实际持仓 179 天 -6bp/年,每年复检;免费长历史被三家交易所 API 封锁(E56 原文),走"测偏+paper funding.csv 自积累"
champion—challenger 制度化	crypto_core_v2 就是:低于 +0.1 替换门槛不换代,平行跑 90 天,10-07 统计裁决器(stats.py ab_test,paired bootstrap),晋升规则预注册
ashare_ml 冻结调参	已冻结:E47 模型冻结、E48 换手缓冲被拒(信号衰减快过省费)、解析性死局已判死(印花税地板 0.64%/年 > 全部费预算 0.55%/年,在任何佣金下不可达),重开条件=分钟线新数据,写在 log
llm 降为低成本观察	已是:实际成本 ~\$1/月(上限 \$30 有机器监控),研发投入为零,跑到 2027-01-14 预注册评估日;其"研究 OS"用途(结果反思/事故复盘)已在用
cb_double_low 不扩资本	已是:2021 依赖警示入档(剔除后 +8.9%→+3.4%),纯前瞻观察
futures_ibkr 人工停止优化	已是:E40b 判"未过门槛",账本唯一目的是攒前瞻记录,制度性禁入组合层

六、用户决策项(●,只摆事实不定夺)

1. **micro-live"买执行信息"**:GPT 的逻辑(纸面再跑三个月对滑点/拒单/队列的 信息增量≈0,极小真钱的 边际信息价值极高)是对的。但 crypto 实盘你已明确保留,我不催;A 股 micro-live 本来就是 QMT 路线图(模拟 30 天门槛不变)。是否在 crypto 上用极小仓位(如 GPT 说的"目标是测量而不是赚钱")重开讨论,由你定。
2. **¥2000—5000 数据预算排序**:GPT 把第一优先从"新 alpha 数据"改为"验证 crypto_core 真实性的 PIT instrument master/独立历史源",第二才是 PIT 基本面,分钟线第三。这个重排有道理(E68 时点宇宙实验若免费数据够用,可以先不花钱;若 OKX/kraken 补不齐 2019 年的死币数据,付费 PIT 源就成为刚需)。先跑 E68,用结果决定这笔钱,预算决策归你。

七、GPT 漏掉的(它要求下一轮审计补充攻击,自曝四条)

1. **现货 K 线配永续成本**:crypto 回测读现货 bars、用永续费率模型,现货/永续 基差与强平机制未建模(代码有注记,简报没写)。主流币基差通常 <10bp,但这是 假设不是测量——clean-room 复现(P1-7) 应顺带用永续 K 线跑一遍对照。
2. **paper 成交假设**:纸面账按 bar 价全额成交,无深度/无部分成交,TCA 脚手架 在首笔真实成交前是空的——所有纸面权益曲线都隐含这层乐观。
3. **窗口由数据可得性决定**:不止 crypto——futures_ibkr 九品种共同窗口仅 2.5 年(log 原文),各账本的"验证年数"实为"数据可得年数",应在证据标签里统一注明。
4. **v2 裁决的统计功效**:GPT 打了 llm 的"一年 250 点功效低",没打 10-07 的 crypto_core vs v2 裁决——90 天日频 A/B 同样只能探测巨大差异。裁决器输出里 应明示检验功效,避免把"未检出差异"读成"无差异"。

八、行动清单(P0 立即/免费,P1 本月,P2 择机)

#	行动	出处
P0-1	E68 预注册:crypto 2019 时点宇宙对照(补抓 EOS/BCH/TRX 等 2019 起 1h,冻结策略原样跑,量化选择偏差)	§3.1
P0-2	trial-family 台账回溯 E1-E67 + DSR 对 1.11/0.48 打折;判决模板加 candidate_count	§3.2/3.3
P0-3	etf_trend 证据重标注(分时代宇宙宽度+分段指标);简报勘误"10 币 7 年"合并陈述	§二.1/3.1
P0-4	E69 预注册:1000 placebo 策略底噪(随机信号/打乱收益/随机参数过同一回测器)	§3.4
P0-5	llm 决策 JSON 加 prompt_sha256	§3.8
P1-6	Data Exposure Registry + 判决数据快照哈希(未来强制,历史补记注明事后)	§3.5/3.6
P1-7	crypto_core clean-room 独立复现(第二数据源+独立实现+逐日 diff;顺带永续 K 线对照)	§3.7/§七.1
P1-8	qmt_exec partial-fill 一等状态(QMT 激活日前)	§4.2
P2-9	decay.py 加 CUSUM 变点检验;熔断文档按三层重述	§4.1
P2-10	组合层 evidence-weighted risk budgeting 设计稿(第 3 本验证账本出现时启用)	§4.4
	micro-live 与数据预算(等 E68 结果 + 你的决定)	§六

默认执行顺序:P0-5(十分钟)→ P0-3(半天)→ P0-1/P0-4 预注册后跑(各一夜)→ P0-2(两天)。P0 全部不改任何账本行为,纯验证/记账,不触碰"改 preset 须预注册" 红线。GPT 30 天清单的第 1 条"暂停新增策略家族"照单全收:E68/E69 是验证已有 策略的元实验,不是新家族;在 P0/P1 清完之前不开任何新 alpha 方向。

本报告判断均已对照 research/log.md 原文与代码核实;引用的实验编号可在 log 中复核。